



Étude de la polysémie avec des embeddings contextuels

CHEN Peng; ZENG Youjia; ZHENG Ting

PLAN

- 01 Constitution du corpus et mots choisis
- 02 Extraction des embeddings
- 03 Score de polysémie
- 04 Réduction de dimensionnalité & Visualisation 2D
- 05 Comparaison avec les ressources lexicales
- 06 Discussion et limites

Hypothèse

Plus un mot est polysémique, plus ses embeddings contextuelles sont dispersés

Mots sélectionnés selon différents degrés de polysémie

photosynthèse, appendicite, hélicoptère, chlorophylle, glace, carte, chef, bureau, grue, souris, plante, pièce, volant, langue, vague, pointe, mousse

Sensibilité du score

- Les embeddings BERT dépendent du contexte
- Le choix des occurrences influence les résultats

Constitution du corpus

- **Corpus utilisé** : Wikipédia français (Hugging Face Datasets)
- **Idée** : distribution naturelle des usages des mots
- **Échantillonnage** :
 - 1 passage du corpus et 1 article sur 30
 - max 2 phrases par mot et par article
 - ~500 phrases par mot
- **Filtrage** :
 - suppression des phrases trop courtes / longues / peu informatives
 - phrases longues → bruit
 - phrases courtes → manque de contexte

→ **Corpus varié reflétant des usages naturels des mots**

Extraction des embeddings & Score de polysémie

Extraction des embeddings

Découpage en subwords : ex. ["mange", "aient"] ou ["man", "ge", "aient"]
contre mBERT : Sensibilité grammaticale : accords en genre et nombre ; valence verbale
Données d'entraînement : surtout sur le français

- Tokenisation de la phrase avec CamemBERT (SentencePiece)
- Localisation du mot cible dans la séquence de tokens (fenêtre glissante)
- Passage dans le modèle → extraction du last_hidden_state (768 dimensions par token)
- Moyenne des vecteurs des sous-tokens du mot cible → 1 vecteur de 768 dim. par phrase

Score de polysémie

- Calcul de toutes les similarités cosinus deux à deux entre les vecteurs d'un même mot
- N phrases → $N(N-1)/2$ paires (ex. 60 phrases = 1770 paires)
- sim_std (écart-type) = score de polysémie : plus il est élevé, plus les sens sont dispersés
 - Ex. glace sim_std = 0,2546 (polysémique) vs appendicite sim_std = 0,0276 (monosémique)

mot	nb_phrases	sim_mean	sim_std	sim_min	sim_max
glace	481	0.7142	0.2546	-0.174	1
volant	450	0.5229	0.2297	-0.3933	1
pointe	393	0.5616	0.1667	-0.2994	1
souris	266	0.6754	0.1546	-0.1605	0.9821
plante	405	0.8091	0.1407	-0.2134	0.9993
mousse	104	0.6884	0.1301	0.0696	0.9834
carte	369	0.6869	0.1301	-0.1461	1
vague	460	0.6973	0.1295	-0.0369	1
chef	455	0.661	0.1261	-0.0283	0.9993
langue	403	0.7094	0.1241	-0.0143	1
pièce	474	0.7668	0.1161	0.0345	0.9943
hélicoptère	164	0.8037	0.1146	-0.0153	0.9983
grue	77	0.8082	0.1141	0.1685	0.9698
bureau	356	0.7284	0.1034	0.1365	1
photosynthèse	46	0.8813	0.0563	0.5453	0.9996
chlorophylle	14	0.8803	0.0405	0.7585	0.9503
appendicite	10	0.9234	0.0276	0.8503	0.9675

sim_std (écart-type) - score de polysémie

- ❖ std > 0.15 : glace, volant, pointe, souris
- ❖ $0.10 \leq \text{std} \leq 0.15$: plante, mousse, carte
- ❖ std < 0.10 : photosynthèse, chlorophylle, appendicite

sim_min - opposition sémantique maximale

- ❖ min < 0 : vecteurs quasi opposés dans l'espace
 - ex. volant, pointe, plante
 - cause : sens issus de champs sémantiques orthogonaux (physique vs abstrait, objet vs action)
- ❖ min très haut : plutôt monosémique

sim_mean — cohésion sémantique globale

- ❖ faible : sens dispersés
- ❖ élevé : usages similaires

1. std élevée + mean faible + min négatif → polysémie forte avec sens opposés (ex. glace, volant)
2. std modérée + mean élevée + min positif → variation contextuelle sans vraie polysémie (hélicoptère, bureau)
3. std faible + mean très élevée + min élevé → terme technique univoque (photosynthèse, appendicite)

Réduction de dimensionnalité-Visualisation 2D

Objectif : vérifier si les embeddings CamemBERT distinguent les différents sens d'un mot dans l'espace vectoriel

Trois Méthodes

- **ACP** — linéaire — préserve la variance globale
- **t-SNE** — non-linéaire — met en évidence les clusters locaux
- **UMAP** — non-linéaire — préserve structure locale et globale

◆ Visualisation interactive : survol d'un point → phrase source

Mot monosémique — ex. *Hélicoptère*

Mots polysémiques — ex. *souris, vague, carte*

->Intuition globalement confirmée

Comparaison avec les ressources lexicales

Mesure de référence : nombre de sens par mot dans 4 ressources

Principe général : définition large de la polysémie ; toutes les catégories grammaticales sont prises en compte (POS confondues).

- **WordNet(NLTK) & BabelNet(API):**

Nombre de synsets français retournés

- **Wiktionnaire(API) & Dictionnaire de l'Académie française(manuel):**





Sections en chiffres arabes uniquement (1. 2. 3...)

Sous-points non comptés → représentent des sous-acceptions, pas des sens distincts

Mesure de corrélation : coefficients de Pearson et Spearman, accompagnés d'un scatter plot avec droite de régression

Résultats – Corrélation avec les ressources lexicales

Ressource	Pearson r	Spearman ρ	Corrélation (interprétation)
WordNet	0,28	0,43	Faible (r) / Modérée (p)/
Wiktionnaire	0,09	0,43	Très faible (r) / Modérée (p)
BabelNet	0,37	0,38	Modérée
Dict. Académie fr.	0,71	0,71	Forte



Discussion & limites

Haut score



polysémie ?



structure syntaxique ? thématique ? style ?

Expériment avec 1000 phrases par mot :

- tendance générale reste cohérente
- dispersion change pour certains mots
 - sensible à composition du corpus & distribution contextuelle
- Il faut corpus plus vaste, annotation manuelle et technique de clustering plus scientifique

MERCI