

Rapport - Etude de la polysémie avec des embeddings contextuels

CHEN Peng, ZENG Youjia, ZHENG Ting

1. Introduction

La polysémie, phénomène par lequel un même mot porte plusieurs sens distincts, est une caractéristique fondamentale des langues naturelles. Les modèles de langue contextuels comme BERT produisent pour un même mot des représentations vectorielles différentes selon le contexte dans lequel il apparaît, offrant ainsi une nouvelle approche pour mesurer automatiquement ce phénomène.

Dans ce travail, nous proposons un score de polysémie basé sur l'écart-type des similarités cosinus calculées entre toutes les paires d'embeddings d'un même mot, extrait de Wikipédia. Un écart-type élevé indique une forte dispersion des représentations, et donc une potentielle polysémie. L'objectif est d'évaluer dans quelle mesure ce score automatique correspond à la notion linguistique de polysémie, en le confrontant à des ressources lexicales de référence et en visualisant la distribution des embeddings par réduction de dimensionnalité.

2. Méthodologie

2.1 Constitution du corpus et Mots choisis

Nous avons utilisé le corpus Wikipédia français disponible sur [Hugging Face Datasets](#). Le corpus était parcouru une seule fois, et les phrases contenant les mots cibles étaient extraites au fur et à mesure du parcours. Pour obtenir des occurrences reflétant une distribution aussi naturelle que possible des différents usages des mots, obtenant des contextes variés et couvrant différents sens possibles, nous avons utilisé une stratégie d'échantillonnage global : seul un article sur trente était analysé. De plus, afin d'éviter qu'un même article domine le corpus, l'extraction était limitée à un maximum de deux phrases par mot et par article. Des filtres de longueur et de qualité ont également été appliqués afin d'éliminer les phrases trop courtes, trop longues ou peu informatives, à partir de seuils définis sur le nombre de caractères et de mots. Enfin, jusqu'à environ 500 phrases ont été collectées pour chaque mot étudié.

Nous avons choisi 17 mots présentant différents degrés de polysémie, en nous appuyant sur les définitions du dictionnaire de l' [Dictionnaire de l'Académie française](#) : *photosynthèse, appendicite, hélicoptère, chlorophylle, glace, carte, chef, bureau, grue, souris, plante, pièce, volant, langue, vague, pointe* et *mousse*.

2.2 Extraction des embeddings contextuels (avec [CamemBERT](#))

Pour extraire les embeddings contextuels, nous avons créé le script [embedding.py](#) en utilisant CamemBERT, modèle de type BERT entraîné spécifiquement sur le français, qui offre une meilleure qualité de représentation que mBERT (nous l'avons essayé aussi avec le script [embedding_mbert.py](#)) pour notre tâche. Contrairement aux embeddings statiques, CamemBERT produit pour chaque occurrence d'un mot un vecteur distinct de 768 dimensions, sensible au contexte phrastique.

La procédure d'extraction repose sur la localisation du mot cible dans la séquence tokenisée, celui-ci pouvant être découpé en plusieurs sous-mots (ex. *hélicoptère* → [*_hélicop*, *tère*]), puis sur la moyenne des vecteurs de ses tokens issus de la dernière couche cachée du modèle.

2.3 Définition du score de polysémie

À partir des N embeddings extraits pour chaque mot, nous calculons les $N(N-1)/2$ similarités cosinus entre toutes les paires d'occurrences. Le score de polysémie est défini comme l'écart-type de ces valeurs : un écart-type élevé traduit une forte dispersion des représentations contextuelles, suggérant que le mot est employé dans des contextes sémantiquement distincts, tandis qu'un écart-type faible caractérise un mot dont le sens reste stable à travers les occurrences.

3. Résultats et Analyse

3.1 Scores obtenus par mot

mot	nb_phrases	sim_mean	sim_std	sim_min	sim_max
glace	481	0.7142	0.2546	-0.174	1

volant	450	0.5229	0.2297	-0.3933	1
pointe	393	0.5616	0.1667	-0.2994	1
souris	266	0.6754	0.1546	-0.1605	0.9821
plante	405	0.8091	0.1407	-0.2134	0.9993
mousse	104	0.6884	0.1301	0.0696	0.9834
carte	369	0.6869	0.1301	-0.1461	1
vague	460	0.6973	0.1295	-0.0369	1
chef	455	0.661	0.1261	-0.0283	0.9993
langue	403	0.7094	0.1241	-0.0143	1
pièce	474	0.7668	0.1161	0.0345	0.9943
hélicoptère	164	0.8037	0.1146	-0.0153	0.9983
grue	77	0.8082	0.1141	0.1685	0.9698
bureau	356	0.7284	0.1034	0.1365	1
photosynthèse	46	0.8813	0.0563	0.5453	0.9996
chlorophylle	14	0.8803	0.0405	0.7585	0.9503
appendicite	10	0.9234	0.0276	0.8503	0.9675

On observe une variation importante des écarts-types selon les mots étudiés, allant de valeurs faibles pour des termes spécialisés (ex. photosynthèse, chlorophylle) à des valeurs plus élevées pour des mots du lexique courant (ex. glace, volant, pointe). Ces résultats constituent une première étape descriptive avant la comparaison avec des ressources linguistiques de référence dans la section suivante.

3.2 Visualisation 2D par réduction de dimensionnalité [\[voir les détails sur GitHub\]](#)

Afin d’explorer la distribution des embeddings contextuels, nous avons appliqué trois méthodes de réduction de dimensionnalité : l’[ACP](#), [t-SNE](#) et [UMAP](#). l’ACP pour la structure globale, et t-SNE ainsi que UMAP pour les regroupements locaux.

Les visualisations ont été réalisées à partir des embeddings CamemBERT de 300 à 500 occurrences par mot extraites de Wikipédia. Les figures interactives permettent d’afficher la phrase source au survol des points.

Les résultats sont globalement cohérents avec les intuitions linguistiques. Pour des mots polysémiques comme *souris* ou *chef*, t-SNE et UMAP font apparaître plusieurs regroupements correspondant probablement à différents sens. À l’inverse, pour un mot plus monosémique comme *hélicoptère*, les points restent répartis de manière diffuse, sans structure nette.

Ces observations suggèrent que les embeddings contextuels capturent partiellement l’information sémantique liée à la polysémie, et que la structure géométrique de l’espace vectoriel reflète en partie les distinctions de sens.

3.3 Corrélation avec une ressource linguistique [\[voir les détails sur GitHub\]](#)

Afin d’évaluer la pertinence du score de polysémie BERT (sim_std), nous l’avons comparé au nombre de sens présents dans quatre ressources lexicales : WordNet, le Wiktionnaire, BabelNet et le Dictionnaire de l’Académie française.

Ressource	Pearson r	Spearman p
WordNet	0,28	0,43
Wiktionnaire	0,26	0,59
BabelNet	0,37	0,38
Académie française	0,71	0,71

Les corrélations avec WordNet, le Wiktionnaire et BabelNet sont faibles ou moyennes. Cela peut venir des différences dans la façon de découper les sens : certaines ressources séparent beaucoup de petits sens, alors que d’autres regroupent plusieurs usages dans une même catégorie.

Le Dictionnaire de l'Académie française montre une corrélation plus forte (0,71). Cette ressource utilise une organisation plus simple et plus stable des sens, ce qui semble mieux correspondre à la dispersion des embeddings de CamemBERT.

Ces résultats montrent que le score `sim_std` capture une partie de la polysémie linguistique, mais qu'il mesure surtout la diversité des contextes d'usage des mots.

4. Conclusion et Discussion

En combinant les résultats des différentes ressources linguistiques, on observe une tendance générale : plus un mot possède de sens (synsets), plus son score a tendance à augmenter. Cela suggère une corrélation positive entre la complexité sémantique d'un mot et la variation de ses embeddings contextuels.

Cependant, cette tendance doit être interprétée avec prudence. La définition même de la polysémie varie selon les ressources lexicales, ce qui rend la comparaison partiellement dépendante du choix du référentiel et justifie nos expériences comparatives. Dans ce cadre, certains mots ne suivent pas parfaitement cette tendance.

Ces écarts peuvent s'expliquer par plusieurs facteurs. Ils peuvent être liés aux caractéristiques du corpus Wikipédia, notamment des déséquilibres de fréquence et une couverture incomplète de certains sens, ainsi qu'aux limites de notre stratégie d'extraction. En particulier, certains mots ayant plusieurs catégories grammaticales peuvent apparaître dans des contextes plus variés, ce qui influence leur score.

En outre, un écart-type élevé ne traduit pas nécessairement une polysémie au sens linguistique strict, mais il peut simplement refléter une forte variation contextuelle, syntaxique ou stylistique au sein d'un même sens.

Enfin, la taille et la diversité du corpus peuvent influencer les résultats. Afin de tester la robustesse de notre méthode, nous avons également expérimenté une stratégie alternative consistant à augmenter le nombre de phrases extraites par mot (jusqu'à environ 1000) et à modifier la fréquence d'échantillonnage (un article sur vingt au lieu de trente). Les résultats obtenus restent globalement similaires, ce qui suggère une certaine stabilité du score proposé.

Globalement, la tendance reste cohérente, mais le score dépend encore de la qualité et de la composition du corpus.

Note d'IA : le français n'étant pas notre langue maternelle, nous avons parfois utilisé ChatGPT pour corriger la grammaire, l'orthographe et certaines expressions maladroites, ainsi que pour nous aider à identifier et corriger les bugs dans le code.